

Esses dois conceitos não são exatamente as mesmas coisas, mas eles estão diretamente conectados. Uma analogia para ajudar a entender como esses dois conceitos estão ligados:

Imagine a Inteligência Artificial como a mente de uma criança em desenvolvimento, ela tem um enorme potencial, pronta para perceber, raciocinar e interagir com o mundo.

Já o Aprendizado de Máquina, ele atua como a pedagogia dessa mente. Ele é o processo educacional onde é apresentado exemplos, experiências e correlações para essa criança, mas não ditamos regras rígidas sobre como ela deve viver (o que seria a programação tradicional), em vez disso, mostramos para ela padrões da realidade, o que é certo e errado, como identificar um objeto ou como prever algo como um evento.

Desta forma, a relação fica estabelecida da seguinte forma: o Machine Learning é a jornada de aprendizado que transforma dados brutos em conhecimento, permitindo que a Inteligência Artificial caminhe sozinha, tomando suas próprias decisões e generalizando o seu conhecimento para diversas situações que nunca foram ensinadas de forma explícita.

2.3. Principais conceitos do Aprendizado de Máquina

Como principais conceitos temos:

- **Conjunto de Dados (Dataset):** Os dados que serão utilizados para ensinar.
- **Aprendizado:** A fase em que o algoritmo vai analisar os dados para identificar padrões e relações.
- **Modelo:** Representação do conhecimento que o algoritmo conseguiu do conjunto de dados.
- **Treinamento:** Fase que o algoritmo recebe o conjunto de dados para aprender.
- **Teste:** Fase que o modelo que foi treinado passa por uma avaliação utilizando dados que não foram utilizados no treinamento.

Para explicar esses conceitos, vamos utilizar a analogia usada anteriormente:

O conjunto de dados é o material de estudo, imaginando que esse *dataset* seja uma pilha de cartões de memória para ensinar crianças. Na frente do cartão as características (*Input*) e no verso está escrito a resposta correta (o rótulo/*output*).

O treinamento é a sessão de estudo, é quando você se senta com a criança e passa os cartões, um por um, mostrando, por exemplo, a foto de um animal e a criança tenta adivinhar. No início ela vai errar bastante, mas toda vez que ela errar você a corrige, isso se repete diversas vezes até ela começar a errar menos.

O aprendizado é o momento em que começa criar conexões, seria o momento em que a criança começar identificar padrões nos cartões que foi mostrado e então ela para de chutar as respostas e cria as regras baseadas nos padrões do que foi mostrado.

O modelo seria a “criança educada” no fim do estudo, ela está pronta para ir ao mundo real e identificar os padrões do conteúdo dos cartões sem sua ajuda, mas antes dela ir, vai ter uma “prova” para ter certeza de que ela aprendeu.

Por fim chega o teste, seria algo como a prova final para saber se a criança aprendeu, os cartões que não foram utilizados para ensinar ela é utilizada agora e mostrado para ela, se ela identificar bem, ela passa no teste (o modelo generalizou bem), se ela não reconhecer, isso significa que ela precisa estudar mais (treinar mais).

Nessa analogia que foi utilizada mostra como seria no aprendizado supervisionado, existem mais tipos de aprendizados, sendo os principais deles: Aprendizado Supervisionado, Aprendizado Não Supervisionado e Aprendizado por Reforço.

2.4. Os desafios atuais do Aprendizado de Máquina

De acordo com o artigo¹, os desafios enfrentados atualmente incluem:

Disponibilidade e qualidade dos dados utilizados para treinar modelos precisos, conseguir dados relevantes e o bastante para treinar o modelo é um desafio dependendo do setor, como nos setores com restrições de privacidade ou onde os dados estão espalhados em várias fontes.

O encontro do equilíbrio certo no treinamento. Um modelo muito complexo pode se ajustar muito aos dados de treinamento, o que pode acabar perdendo a capacidade de generalizar para novos dados e um modelo muito simples pode não conseguir encontrar padrões importantes nos dados.

Modelos como redes neurais profundas podem ser muito complexos e difíceis de interpretar, o que em aplicações, como por exemplo, a área médica, é de extrema importância entender como o modelo chegou nas suas decisões.

Conforme o modelo e o conjunto de dados cresce, a escalabilidade acaba se tornando um desafio, devido a quantidade de dados necessária para que eles funcionem de forma eficiente.

2.5. Áreas para a aplicação e interação

Atualmente diversas empresas e setores estão usando a IA e o Aprendizado de Máquina para mudar a forma como estão trabalhando, o que ajuda impulsionar a

¹ <https://www.linkedin.com/pulse/intelig%C3%A2ncia-artificial-e-aprendizado-de-m%C3%A1quina-rela%C3%A7%C3%A3o-monjane/>

produtividade, eficiência e a melhora de tomadas de decisões baseada em dados e análises preditivas, também aprimorando a experiência dos clientes e funcionários. Os setores na qual já está sendo comum a aplicação da IA e ML são: Medicina e Saúde, Ciência biológica, Setor financeiro, Agricultura, Processamento de linguagem natural (chatbots inteligentes, análise de sentimentos em redes sociais), Visão computacional, Cidades inteligentes, Fabricação e Comércio eletrônico e varejo.

3. Conclusão

A Inteligência Artificial e o Aprendizado de Máquina são conceitos diferentes, porém, dependem um do outro. Enquanto a IA representa um objetivo mais amplo de simular a capacidade cognitiva humana, o ML atua como o método que torna possível essa autonomia por meio de uma análise de dados. Mesmo com os desafios existentes, o uso de forma conjunta dessas tecnologias se tornou essencial para a inovação e eficiência em diversos setores.

Referências:

Google Cloud, “Inteligência artificial (IA) x machine learning (ML)”, <https://cloud.google.com/learn/artificial-intelligence-vs-machine-learning?hl=pt-br>

Monjane, A. A., “Inteligência Artificial e Aprendizado de Máquina - Relação, conceitos, desafios e áreas de Integração”, <https://www.linkedin.com/pulse/intelig%C3%A2ncia-artificial-e-aprendizado-de-m%C3%A1quina-rela%C3%A7%C3%A3o-monjane/>