

Relatório 13 - Predição e a Base de Aprendizado de Máquina

Edryck Freitas Nascimento

1. Introdução

O objetivo desta aula foi aprender sobre técnicas de regressão (linear, polinomial e múltipla) para modelos de predição, conceito de train/test split para encontrar overfitting, modelos de classificação (árvore de decisão, random forest e XGBoost), modelo não supervisionado (K-Means), SVM para modelo separando por classes e Naive Bayes para classificação baseada em texto. Ao final, desenvolver algo prático.

2. Desenvolvimento

Optei por seguir a ordem das aulas, do curso Machine Learning, Data Science and Deep Learning with Python, e tentei reutilizar todas as funções feitas na aula e aplicar todas a um mesmo dataset, no meu caso, utilizei o dataset do Titanic. Segui a seguinte sequência:





Figura 1. Sequência das aplicações dos conceitos aprendidos. (autoria própria)

- **Obtenção de Dados:** Desta vez, optei por pegar o notebook direto do site¹, peguei o dataset do repositório do GitHub datasciencedojo, o dataset do Titanic.
- **Preparação dos Dados:** Realizei o carregamento do dataset, em seguida, verifiquei o formato (quantidade de linhas e colunas) e a quantidade de valores faltantes. Então, em seguida, preenchi os valores faltantes das colunas Age e Fare com a mediana e da coluna Embarked com a moda, para os valores categóricos, substitui os das colunas Sex e Embarked por valores numéricos (0 e 1 para sexo e 1, 2, 3 para local onde embarcaram). E por último, adicionei uma nova coluna de tamanho da família (FamilySize), na qual ela continha a soma da coluna SibSp com Parch.
- **Regressão Linear:** Usei a regressão linear para verificar se havia alguma relação entre idade e tarifa, utilizei a métrica R^2 , resultou em um R^2 baixo (0,0093), afinal a tarifa depende mais classe do passageiro do que da idade dele. Então, tentei usar regressão polinomial para tentar pegar essa relação de forma melhor.
- **Regressão Polinomial com Train/Test Split:** Nesta etapa, reutilizei o código da aula e adaptei para o meu caso de uso, utilizei diferentes graus usando np.polyfit e avaliei os conjuntos de teste para tentar encontrar algum overfitting, a divisão dos dados para treino e teste foi de 80/20 (80% para treino e 20% para teste).

Overfitting: quanto maior o grau, pior no teste



Como pode ser visto nos gráficos, quanto maior o grau, maior o overfitting, então fui tentar de outra forma, agora com a regressão múltipla, com múltiplas features, os coeficientes vão mostrar as variáveis que mais influência na tarifa.

- **Regressão Múltipla:** Seguindo o código parecido com o da aula, consegui os seguintes resultados:

¹ <https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv>

<i>Variável</i>	<i>Coeficiente</i>	<i>P-Valor</i>
<i>const</i>	~32.2	~0.0
<i>Pclass</i>	~-28.7	~0.0
<i>FamilySize</i>	~12.2	~0.0
<i>Age</i>	~-1.9	~0.17

Tabela 1. Tabela de coeficientes simplificada do notebook. (autoria própria)

O const igual aproximadamente 32.2 indica a tarifa base, na média das variáveis, embora o coeficiente do Pclass esteja negativo, iremos utilizar o módulo dele, ele se mostrou ser o principal fator para a tarifa, ou seja, quanto maior a classe, menor é a tarifa. O tamanho da família (FamilySize) também se mostrou um fator que altera a tarifa, afinal, quanto maior a família, maior a tarifa. Já a idade (Age), devido ao P-valor, não tem um certo efeito quando é controlada pelas outras.

Já as métricas do modelo:

Métrica	Valor
R²	0.36
R² ajustado	0.36
F-statistic	172.0
P (F-statistic)	7.04e-88 (praticamente zero)

Tabela 2. Tabela simplificada do notebook, qualidade do modelo. (autoria própria)

O R² mostra que o modelo explicou 36% da variação das tarifas.

O R² ajustado, ele é penalizado pela quantidade de variáveis, quase igual ao R², isso indica que o modelo não está inflado.

O F-statistic mostrou que o modelo é globalmente significativo.

P (F-statistic) é praticamente zero, então não é um resultado aleatório.

Ao realizar duas previsões de tarifas, usando os dois exemplos, resultou nos seguintes resultados:

Tarifa prevista para 1ª classe, 30 anos, sem família: £70.32

Tarifa prevista para 3ª classe, 30 anos, sem família: £1.46

- **Árvores de decisão e random forest:** Utilizei a árvore de decisão para facilitar a interpretação e a random forest para mostrar como o ensemble

reduz a variância, foi utilizado para prever se sobreviveu ou não, a acurácia da árvore de decisão foi de aproximadamente 0.81 e utilizei o graphviz para visualizar a árvore de decisão (obs: alterei a profundidade da árvore para 3 para melhor visualização, ficava uma imagem muito grande e dificultava a visualização, mas fiz isso em uma cópia do notebook).




Figura 2. Visualização da árvore de decisão. (autoria própria)

Já na random forest, a acurácia foi de 0.82, realizando dois testes e obti os seguintes resultados (0: não sobreviveu, 1:sobreviveu):

Mulher, 1ª classe, 25 anos: [1]

Homem, 3ª classe, 25 anos: [0]

- **XGBoost:** Usei o XGBoost no mesmo problema da random forest para comparar o boosting, ele corrige os erros de forma sequencial, contra o bagging da random forest. Alcancei uma acurácia de 0.83, comparado com a árvore de decisão e a random forest:




Figura 3. Gráfico de comparação da acurácia dos três modelos. (autoria própria)

Esses três modelos (árvores de decisão, random forest e XGBoost) eram do tipo supervisionado, agora seguindo, vou usar o K-Means, ele foi o único modelo não supervisionado mostrado nos módulos cobrados.

- K-Means:** Fazendo os mesmos treinamentos que os três anteriores, neste, por ser um modelo não supervisionado, eu removi a coluna Survived (que indica se o passageiro sobreviveu ou não) e separei as colunas Age, Fare e Pclass para clustering, depois comparei, pintando os pontos de sobrevivência real para ver se os clusters coincidiam.




Figura 4. Comparação dos dois gráficos, um do resultado de treinamento usando K-Means e outro com os dados reais. (autoria própria)

- **SVM:** Agora usando testando com diferentes kernels com o SVM, não vou entrar em muitos detalhes nele, mas com o kernel linear e o RBF, consegui as seguintes acurácias para cada kernel:

Acurácia SVM linear: 0.66

Acurácia SVM RBF: 0.69

Testando as previsões, consegui estes resultados:




Figura 6. Gráfico dos resultados usando o kernel linear. (autoria própria)




Figura 6. Gráfico dos resultados usando o kernel RBF. (autoria própria)

Testando as previsões, escolhi alguns dados específicos e consegui a seguinte previsão:

Mulher jovem, tarifa alta: [1]

Homem mais velho, tarifa baixa: [0]

- **Naive Bayes:** O último modelo, este para é o único visto nos módulos pedidos, que é orientado a texto. No campo de nome do dataset tem títulos como Mr, Mrs, Miss, Master, Dr, Rev, usei isso para prever a sobrevivência do passageiro. Testando com alguns nomes, consegui isso:

Miss. Anna Smith - Sobreviveu

Mr. John Jones - Não sobreviveu

Mrs. Mary Brown - Sobreviveu

Master. James Taylor - Sobreviveu

Dr. Robert Wilson – Sobreviveu

Aplicando Train/Test Split no Naive Bayes, com uma divisão de 80/20 (80% treino e 20% teste), consegui esta acurácia:

Acurácia Naive Bayes (train): 0.91

Acurácia Naive Bayes (test): 0.79

- **Métricas usadas para cada modelo:**

Modelo	Métrica
Regressão Linear	R ² (relação fraca)
Regressão Polinomial	R ² , treino/teste, overfitting visto no grau 8
Regressão Múltipla	Coeficientes OLS
Árvore de Decisão	Acurácia
Random Forest	Acurácia

XGBoost	Acurácia
K-Means (k=3)	Clusters comparados com a sobrevivência real
SVM (linear e RBF)	Acurácia + regiões de decisão
Naive Bayes	Acurácia e treino/teste

3. Conclusão

Notei que não existe um método ideal, depende muito do tipo de problema, dos dados disponíveis e do nível de interpretação do problema, aplicando todos os modelos no mesmo dataset foi possível comparar o comportamento de cada um. Os modelos de regressão mostraram o principal fator na tarifa. Dos de classificação, o XGBoost ficou acima da árvore de decisão e da Random Forest em acurácia, assim, mostrando a vantagem do boosting em relação ao bagging nesse dataset. O K-Means mostrou padrões sem nenhuma informação de sobrevivência, basicamente, aprendizado não supervisionado na prática. O SVM, mesmo com acurácia baixa, mostrou que diferentes kernels produz decisão bem diferentes. O Naive Bayes também mostrou que até os nomes carrega informação preditiva útil, se for bem explorado.

4. Referências

Curso: Machine Learning, Data Science and Deep Learning with Python

Módulos: Predictive Models e Machine Learning with Python

Dataset: <https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv>