

Relatório 14 - Redes Neurais

Edryck Freitas Nascimento

1. Introdução

O objetivo desta aula foi aprender sobre Redes Neurais e a prática de construir uma rede neural. A tarefa consistia em assistir as aulas do curso “Deep Learning com Python de A a Z” e, posteriormente, realizar uma atividade prática para demonstrar domínio sobre o que foi aprendido.

2. Desenvolvimento

- **Obtenção de Dados:** Inicialmente, foi baixado um *dataset* com informações de pacientes com diabetes. O objetivo foi prever se um paciente tem ou não diabetes, basicamente, um problema de classificação binária.
- **Preparação dos Dados:** Nesta etapa, realizei a limpeza dos dados, que incluiu a análise do *dataset*, a separação da coluna de resultados e a divisão dos conjuntos de treino e teste (defini 20% para teste e 80% para treino).
- **Configuração do Modelo:** Após utilizar o cálculo de número de coluna + 1 e dividir o resultado por dois para definir a quantidade de neurônios na camada oculta, obtive o resultado de 5 neurônios na camada oculta, utilizei duas camadas ocultas, também utilizei a função de ativação ReLU para as camadas ocultas e a função sigmoid para a camada de saída, já que como dito anteriormente, é um problema de classificação binária.
Usei o otimizador Adam com a taxa de aprendizado de 0.001 (o padrão do otimizador Adam), compilei o modelo usando a função de perda `binary_crossentropy`, o otimizador Adam e a métrica de acurácia binária.
- **Treino:** Realizei o treino usando a validação cruzada K-Fold, usando o valor de k padrão ($k = 10$). Após o treino, a média do 10 Fold foi de aproximadamente 0.705, com um desvio padrão de 0.073, que é o quanto eles variam em relação à média. Esses resultados indicam que estão próximos da média, então até que teve um desempenho bom.
- **Métricas:** Agora mediando o desempenho do modelo, ele teve uma acurácia de aproximadamente 78%. A matriz de confusão obtida:




Figura 1. Matriz de confusão do modelo. (autoria própria)

Lendo a matriz, o modelo acertou corretamente 89 pessoas que realmente não tinham diabetes e 31 pessoas que tinham diabetes, porém, previu incorretamente 24 pessoas que tinham diabetes (que tinham diabetes, mas ele previu que não) e 10 que não tinham (previu que tinham diabetes, mas não tinham).

Sobre as métricas:




Figura 2. Gráfico de barras com as métricas utilizadas para avaliação do modelo.
(autoria própria)

Como pode ser observado no gráfico, o modelo tem 78% de acurácia, com precisão de 76%, ou seja, a cada 100 pessoas, ele prevê corretamente cerca de 76 pessoas, um Recall de 56%, isso indica que modelo é capaz de identificar corretamente 56% dos casos corretamente e F1 Score de 65%, ele indica o equilíbrio entre precisão e recall, ou seja, o modelo tem um desempenho mediano tanto em identificar os casos positivos quanto em evitar falsos positivos.

A curva ROC mostrou que o modelo tem uma boa capacidade de discriminação entre classes, com uma área sob a curva (AUC) de aproximadamente 0.73, o que indica que o modelo tem uma boa capacidade de distinguir entre pacientes com e sem diabetes.




Figura 3. Curva ROC e AUC do modelo. (autoria própria)

- **Carregar Melhor Modelo:** Também tentei realizar o mesmo treino com um Dropout, mas ele não conseguiu identificar ninguém que tinha diabetes, apenas identificava quem não tinha diabetes, logo, descartei este modelo.

3. Conclusão

Este está rede neural de classificação binária para previsão de uma pessoa ter ou não diabetes se mostrou razoavelmente eficaz, embora sua eficácia e precisão seja alta, ainda é possível refinar ainda mais para aumentar sua precisão. Embora eu não tenha feito uma de classificação múltiplas saídas, como o exemplo de jogos, mostrado na aula, ainda seria bastante interessante fazer um que previsse múltiplas doenças.

4. Referências

Curso: <https://www.udemy.com/course/deep-learning-com-python-az-curso-completo/learn/lecture/12845420?start=1#overview>.

Dataset: <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>.