

Relatório 20 - Como Estamos Ensinando os Computadores a Compreender Fotos

Edryck Freitas Nascimento

1. Introdução

O objetivo desta aula foi aprender sobre como faz para ensinar os computadores a compreender fotos através do vídeo “*How we teach computers to understand pictures*” da Fei Fei Li. A tarefa consistia em assistir o vídeo e escrever um relatório sobre o conteúdo do vídeo.

2. Desenvolvimento

Basicamente, o vídeo em questão é sobre de uma palestra, tendo a palestrando Fei Fei Li, especialista em Visão Computacional. A palestra se trata sobre Visão Computacional, uma subárea da Inteligência Artificial, assim como o Aprendizado Computacional.




Figura 1. Algumas subáreas da Inteligência Artificial. (autoria própria)

Pelo título deste documento, acredito que seja possível saber que o ponto principal seja sobre como as máquinas estão sendo ensinadas a compreender fotos, dentro dos campos de fotos entra vídeos também (um vídeo é composto de diversos frames, cada frame é uma captura do ambiente em respectivo momento do tempo). Fei Fei Li diz na palestra cita sobre a dificuldade do software mais avançado ter dificuldades de

compreender este tipo de conteúdo, nossas máquinas são cegas. Porém, vale notar que no momento que estou escrevendo este relatório, esta palestra tem 11 anos desde sua publicação, o que quero dizer é que de 11 anos atrás até o momento, houve muita coisa nova, muitas descobertas, as pesquisas avançaram bastante.

Durante minha pesquisa, enquanto assistia o vídeo, encontrei alguns artigos que seguem até uma ordem cronológica para mostrar esses avanços:




Figura 2. Ordem cronológica. (autoria própria)

Entre 2009 e 2014¹, Fei Fei Li, juntamente de sua equipe, criaram o dataset e o desafio anual (ILSVRC) com milhões de imagens rotuladas em milhares de categorias. O projeto é o ImageNet, iniciado em 2007. Basicamente é o foco da palestra, ela explica de forma mais superficial sobre o como feito para ensinar as máquinas a verem (RUSSAKOVSKY, O. et al.).

Em 2015, descobriram que apenas empilhar camadas e mais camadas em uma rede neural piorava o desempenho e não melhorava. Então o ResNet, uma arquitetura de rede neural profunda feita por pesquisadores da Microsoft Research, resolveu isso com “conexões residuais” (ResNet significa Residual Network, ou sem português, Rede Residual), são atalhos que deixam informações pular camadas. Treinaram redes de até 152 camadas com isso e derrubaram o erro no ImageNet para 3,57%, que pela primeira vez a taxa de erro humana estimada foi superada (por volta de 5%) (HE, K. et al.).

Em 2020, até então as CNNs eram a única arquitetura viável para visão computacional, mas o ViT (Vision Transformer) mostrou que dá para cortar imagens em pedaços e tratar cada um como se fosse uma “palavra” e processar tudo com Transformer, a mesma arquitetura usada em modelos de linguagem. Ele funciona bem, mas só se for treinado com muitos dados, muitos no sentido de dezenas a centenas de milhões de imagens (DOSOVITSKIY, A. et al.).

Já em 2021, o CLIP (Contrastive Language-Image Pre-training, um modelo de rede neural multimodal) da OpenAI aprendeu associando imagens com suas legendas com texto livre, foi usando 400 milhões de pares de imagens-texto da internet e teve como resultado classificar categorias que nunca viu rotuladas de forma explícita, na prática é como se ele entendesse o conceito por linguagem e não por rótulo fixo. Eles saíram de aprender com categorias fixas para categorias sem ser rotuladas explicitamente (RADFORD, A. et al.).

¹ A data de publicação do vídeo é 2015

3. Conclusão

A visão computacional, digamos que atua como os olhos das máquinas, assim como daria para considerar o aprendizado de máquina como a aprendizagem dela. Ao assistir está palestra, umas das primeiras coisas que eu fiz foi ver a data de publicação, o me incentivou a buscar sobre os avanços da visão computacional, assim encontrei os artigos na qual usei como base para falar sobre os avanços, desde 2009 (início do ImageNet) até próximos dos dias atuais (neste caso, vi até 2021). Está área da Inteligência Artificial é uma que ainda hoje tem alguns desafios a serem superados, mesmo após todos esses avanços.

4. Referências

LI, Fei-Fei. How we teach computers to understand pictures. TED, 2015. 1 vídeo (18 min). Disponível em: <https://www.youtube.com/watch?v=40riCqvRoMs>.

RUSSAKOVSKY, O. et al. ImageNet Large Scale Visual Recognition Challenge. arXiv:1409.0575, 2014.

HE, K. et al. Deep Residual Learning for Image Recognition. arXiv:1512.03385, 2015.

DOSOVITSKIY, A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. arXiv:2010.11929, 2020.

RADFORD, A. et al. Learning Transferable Visual Models From Natural Language Supervision. arXiv:2103.00020, 2021.