Relatório 26 - Métricas e Validação de Modelos de Aprendizado de Máquina

Edryck Freitas Nascimento

1. Introdução

O objetivo desta aula foi aprender sobre como cada métrica responde, como compará-las entre os modelos e como explicar uma predição. A tarefa consistia em assistir os dois vídeos com os conceitos, um fala sobre métricas de classificação (matriz de confusão, precisão, recall, curva ROC, cutoff) e o outro sobre SHAP (que explica as decisões de modelos “caixa-preta”.

2. Desenvolvimento

A ordem das métricas:

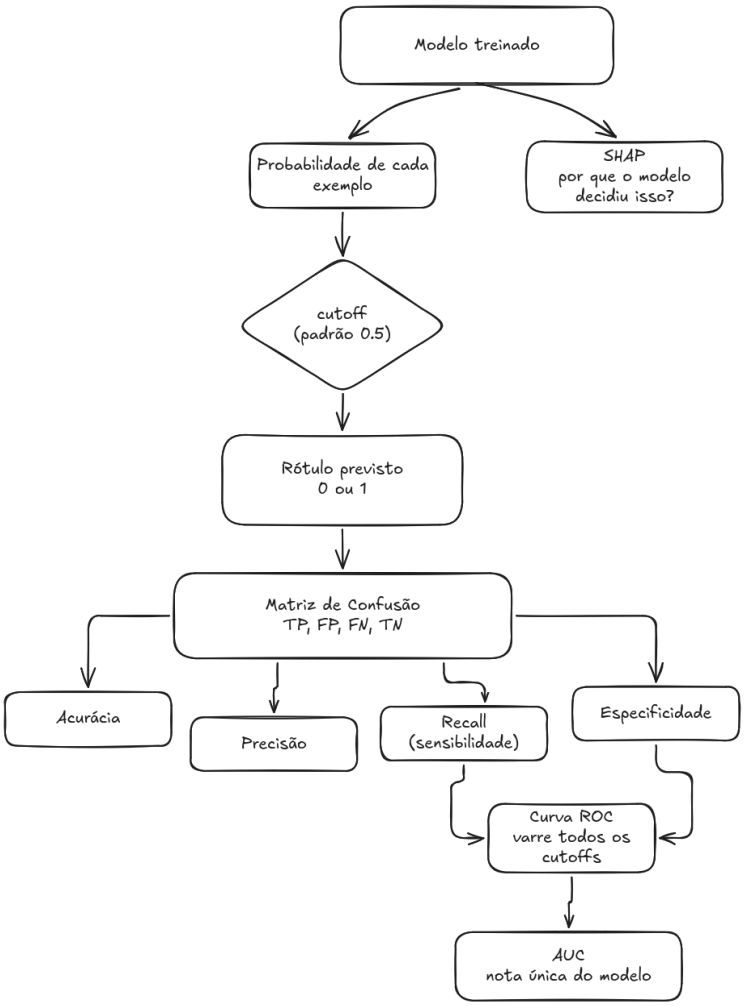


Figura 1. Métricas. (autoria própria)

Enquanto uma parte responde “o modelo é bom?”, o SHAP responde “por que ele decide assim?”. Essas duas coisas são necessárias porque um modelo pode até ter métricas muito boas e ainda assim decidir pelo motivo errado.

A base de tudo é a matriz de confusão, ela é o cruzamento entre o que o modelo previu e o que realmente aconteceu, dela saem os quatro números (verdadeiro positivo, falso positivo, falso negativo e verdadeiro negativo) a partir deles que as outras métricas são calculadas.

Obs.: As métricas desta aula valem para classificação, para regressão as regras não são as mesmas.

O que cada métrica responde?

- **Acurácia ((TP + TN) / total):** Quanto que o modelo acerta no geral?
- **Precisão (TP / (TP + FP)):** De todos que eu previ como positivo, quantos eram?
- **Recall (TP / (TP + FN)):** De todos os positivos reais, quantos eu peguei?
- **Especificidade (TN / (TN + FP)):** De todos os negativos reais, quantos eu reconheci?

Precisão e recall puxam lados opostos, a precisão olha para a coluna que o modelo previu e o recall para a linha do que aconteceu, então não é bom usar nenhuma delas sozinha. Ex.: Se eu declarar que todo mundo é fraudador, o recall vai a 100% (porque eu peguei todos os fraudadores), mas a precisão despenca (acusei todos os inocentes).
A especificidade é o “recall” da outra classe, ela é a peça que falta para montar a curva ROC (vou falar sobre mais para baixo).

Cutoff

O modelo não responde com sim ou não, ele responde uma probabilidade. O rótulo só aparece depois de um corte (o cutoff), que por padrão é 0.5. O aprendizado do modelo é o mesmo em qualquer corte, ele só muda a decisão e a todas as métricas. Eu entendi que o cutoff é, basicamente, uma decisão de negócio, não uma estatística. A live (vídeo do canal Téo Me Why) deu umas formas de escolher:

- Pelo risco aceito: em fraude, definir quanto de chargeback a empresa tolera e achar o corte que respeita isso.
- Pelo volume: em campanha, ordenar por probabilidade e abordar os N primeiros.
- Por matriz de custo: atribuir um valor a cada tipo de acerto e erro e escolher o corte que maximiza o ganho.
- Por percentis: olhar precisão e recall de 5 em 5% de probabilidade.

Curva ROC e AUC

Para cada cutoff possível, é calculado a sensibilidade (eixo Y) e 1 - especificidade (eixo X), ligando os pontos aparece a curva. Não existe fórmula fechada, ela é uma curva empírica, construída dos dados.
Basicamente, quanto mais próxima no canto superior esquerdo, melhor o modelo separa as classes, a diagonal é o chute aleatório.
A área sob a curva, de 0 a 1, resume a curva em um número, isso é o AUC.
Enquanto a acurácia, precisão e recall são métricas pontuais, ou seja, valem para um corte só, a ROC avalia a qualidade da probabilidade inteira.

SHAP

As árvores de decisão se explicam sozinhas, mas um SVM entrega só o 0 ou 1, sem probabilidade e sem justificativa. O SHAP (SHapley Additive exPlanations) vem da teoria dos jogos, cada variável é um "jogador" e o SHAP calcula quanto cada uma contribuiu para a predição, empurrando para um lado ou para o outro a partir de um valor base.
É separado em dois níveis de leitura:

- **Global (summary plot):** mostra quais variáveis mais pesam no modelo e em que direção (a cor indica se o valor da variável é alto ou baixo).
- **Individual (force plot):** mostra como as variáveis empurraram uma predição específica.

Tirando a média dos valores absolutos do SHAP por variável, consegue um ranking de importância mesmo para modelos que não oferecem isso. O KernelExplainer funciona com qualquer modelo, mas é lento, o vídeo resume os dados de fundo com k-means (10 centróides) para acelerar.
Em relação com o LIME, o LIME explica localmente com um modelo simples ao redor da instância, mas o SHAP tem fundamento teórico mais sólido (valores de Shapley).

Prática

Como não tinha acesso à base da live (bem antigo e o link do Drive não existe mais), repliquei os conceitos no dataset Breast Cancer Wisconsin, o mesmo usado no vídeo de SHAP (569 exemplos e 30 variáveis). Escolhi isso por:

- **Classe positiva = maligno:** No dataset original o maligno é 0, mas o evento de interesse é detectar o tumor maligno. Invertendo, o recall passa a medir "quantos tumores malignos eu peguei", que é a pergunta clínica.
- **Divisão 80/20 estratificada** (455 treino, 114 teste). Estratificar mantém a proporção de malignos nas duas partes (37% no teste).
- **Comparação árvore vs. random forest** (350 árvores, min_samples_leaf=5), como foi feito na live.

- **Validação cruzada de 5 partes** como reforço (o que eu adicionei): com só 114 exemplos de teste, uma única divisão pode enganar.

Usando o corte de 0.5, consegui os seguintes resultados no teste:

Métrica	Árvore sem limite	Random forest
Verdadeiro negativo / Falso positivo	68 / 4	72 / 0
Falso negativo / verdadeiro positivo	4 / 38	3 / 39
Acurácia	0.930	0.974
Precisão	0.905	1.000
Recall	0.905	0.929
Especificidade	0.944	1.000
AUC no treino	1.000	0.998
AUC no teste	0.925	0.994
AUC em validação cruzada (5 partes)	0.916	0.991

Na leitura destas métricas, é possível observar duas coisas:

- **Sinal clássico de overfitting:** a árvore tem AUC de treino 1.000 e de teste 0.925, ou seja, decorou o treino. A random forest quase não perde de treino para teste, e a validação cruzada confirma (0.991).
- **A acurácia esconde o tipo de erro,** a forest tem precisão 1.000, mas ainda deixa passar 3 tumores malignos (falsos negativos). em diagnóstico, esse erro é um erro caro, e a acurácia de 97% não mostra isso.

Mexendo só no cutoff da random forest:

Cutoff	Falsos positivos	Falsos negativos	Precisão	Recall	Acurácia
0.1	14	0	0.750	1.000	0.877
0.3	2	3	0.951	0.929	0.956
0.5	0	3	1.000	0.929	0.974
0.7	0	7	1.000	0.833	0.939
0.9	0	17	1.000	0.595	0.851

Este resultado ensinou bastantes que o mesmo modelo, sem retreinar, passa de recall 1.000 a 0.595 só mudando o corte. COm 0.1 não escapa nenum tumor, ao custo de 14 alarmes falsos. Em triagem médica dá para aceitar isso, mas em uma campanha de marketing… provavelmente não. É exatamente a ideia de que o corte depende do custo de cada erro.
SHAP no SVM linear (LinearSVC, acurácia de teste 0.930, não fornece probabilidades), explicando 40 exemplos de teste:

Posição	Variável (SHAP sobre a função de decisão)	Média do |SHAP|
1	mean radius	3.514
2	worst area	2.513
3	mean perimeter	2.352
4	worst texture	1.357
5	mean area	0.849

Como o SVM é linear, dá para conferir com os próprios coeficientes (peso x desvio-padrão). As 3 primeiras variáveis coincidem (mean radius, worst area, mean perimeter). O SHAP encontrou sozinho o que o modelo já “sabia”.
Sobre a aditividade, para um exemplo, o valor base somado às contribuições dá -2.3615, idêntico à saída real do modelo (-2.3615). Isso é o “Additive” do nome, ou seja, as contribuições fecham a conta.

Limitações

Algumas limitações nesta práticas foram:

- O teste tem só 114 exemplos, então diferenças pequenas (como 0.974 vs. 0.956) não são conclusivas.
- A replicação usa um dataset limpo e pequeno. Não reproduzi a base out of time da live, que depende de dados com recorte temporal.
- O SHAP foi calculado em 40 exemplos para economizar tempo.
- Não explorei KS, curva de aprendizado nem otimização automática do corte, já que na live diz que seriam os próximos passos.

3. Conclusão

Não existe “a” métrica de um modelo, cada uma responde uma pergunta diferente e a certa depende do custo do erro. A acurácia sozinha esconde falsos negativos, precisão e recall são uma balança que se move com o cutoff, e a curva ROC/AUC é a mais confiável porque avalia todos os cortes e não só um. Na prática é possível

ver que o mesmo modelo vai de recall 1.0 a 0.6 só mudando o corte e que um AUC de treino de 1.0 contra 0.92 no teste denúncia overfitting. por isso a validação precisa ser feita em dados que o modelo não viu, de preferência em mais de uma base. O SHAP completa o quadro explicando por que o modelo decide.

4. Referências

CALVO. T. **COMPARANDO MODELOS DE MACHINE LEARNING!!** YouTube, 2020. Vídeo. Disponível em: https://www.youtube.com/watch?v=_Y1SWuKr4Tg.

NEURALNINE. **Explain Machine Learning Models with SHAP in Python**. YouTube, 2024. Vídeo. Disponível em: https://www.youtube.com/watch?v=zyXapWWWGG4.

SHAP. **SHAP documentation**. Disponível em: https://shap.readthedocs.io. Acesso em: 19 out. 2026.

WOLBERG, W. H.; STREET, W. N.; MANGASARIAN, O. L. **Breast Cancer Wisconsin (Diagnostic)**. UCI Machine Learning Repository, 1995. Disponível em: https://archive.ics.uci.edu/dataset/17. Acesso em: 19 out. 2026.